Modélisation du risque d'assurance par simulation Monte-Carlo

Projet personnel en Python — Analyse méthodologique

Nom : AISSIOU Naila Yasmine · Mathématiques financières, Université de Montréal

Ce document accompagne le notebook Python du projet. Il s'agit d'un projet pédagogique : le portefeuille est fictif et les paramètres ont été choisis à des fins d'illustration. Ils ne proviennent d'aucune donnée réelle et ne sont pas des statistiques officielles.

1. Présentation du projet et méthodologie

Objectif et modèle fréquence-sévérité

L'objectif est de simuler les pertes annuelles d'un portefeuille fictif de 1 000 assurés pour comprendre comment la perte totale d'un assureur résulte du nombre de sinistres et de leur coût, puis pour interpréter la perte attendue, des probabilités de dépassement et un quantile. Le modèle fréquence-sévérité sépare le risque en deux composantes : la **fréquence** (le nombre N de sinistres du portefeuille sur un an) et la **sévérité** (le coût X_i du i-ième sinistre). La perte annuelle totale est

$$S = \sum_{i=1}^{N} X_i \qquad (S = 0 \text{ si } N = 0)$$

Si les X_i sont indépendants, de même loi, et indépendants de N, la perte attendue est

$$\mathbb{E}[S] = \mathbb{E}[N] \cdot \mathbb{E}[X]$$

Hypothèses et choix des distributions

Le portefeuille compte n = 1 000 assurés observés pendant un an. Pour chaque assuré, le nombre de sinistres suit une loi de Poisson de paramètre $\lambda = 0{,}2$ et le coût de chaque sinistre suit une loi exponentielle de moyenne μ = 1 500 $. Les assurés ont tous la même fréquence ; leurs nombres de sinistres sont indépendants, et les coûts sont indépendants entre eux et de la fréquence. Ce sont des **hypothèses**, non des constats, et les valeurs numériques n'ont pas été estimées sur des données.

$$P(N_j = k) = e^{-\lambda}\frac{\lambda^k}{k!} \quad (\mathbb{E}[N_j] = \mathrm{Var}(N_j) = \lambda) \qquad f(x) = \frac{1}{\mu}e^{-x/\mu},\ x \geq 0 \quad (\mathbb{E}[X] = \mu,\ \mathrm{Var}(X) = \mu^2)$$

La **loi de Poisson** convient pour compter des événements indépendants sur une période fixée, avec un seul paramètre. Elle est stable pour la somme : le nombre total de sinistres du portefeuille suit une loi de Poisson de paramètre 1 000 × 0,2 = 200. Sa limite est l'**équidispersion** (variance égale à la moyenne). La **loi exponentielle** est positive, asymétrique et simple, mais un seul paramètre fixe à la fois la moyenne et la dispersion, et sa queue décroît vite, ce qui peut sous-estimer les très gros sinistres. La binomiale négative (fréquence plus dispersée), la gamma (paramètre de forme supplémentaire) et la lognormale (queue plus épaisse) sont des alternatives possibles, sans être systématiquement meilleures : le choix dépend des données.

2. Simulation Monte-Carlo et résultats

Méthode

Pour chaque année simulée, le code tire directement le nombre total de sinistres du portefeuille selon une loi de Poisson de paramètre 200, puis simule les coûts individuels correspondants (exponentielle de moyenne 1 500 $) et les additionne pour obtenir S. Les assurés ne sont donc pas simulés un par un à chaque itération, ce qui est équivalent ici puisque la somme de 1 000 lois de Poisson de paramètre 0,2 est une loi de Poisson de paramètre 200. L'opération est répétée 10 000 fois : la moyenne de l'échantillon estime $E[S]$, la proportion d'années au-dessus d'un seuil estime une probabilité, et le quantile empirique estime un quantile de S. Ce nombre d'années est un compromis entre précision et temps de calcul. La variance de S se calcule à la main :

$$\mathrm{Var}(S) \;=\; \mathbb{E}[N]\,\mathbb{E}[X^2] \;=\; 200 \times 2 \times 1\,500^2 \;=\; 9 \times 10^8$$

L'écart type de la perte annuelle est donc de 30 000 $ et l'erreur-type de la moyenne simulée est d'environ 30 000 / √10 000 = 300 $ (0,1 % de la perte attendue) : c'est suffisant pour estimer une moyenne, mais nettement moins pour des événements rares.

Résultats

Quantité	Théorique	Simulé
Première simulation annuelle		
Nombre total de sinistres	200	205
Assurés sans sinistre	≈ 818,7	811
Coût moyen par sinistre	1 500,00 $	1 463,88 $
Perte totale	300 000 $	300 094,59 $
Simulation Monte-Carlo (10 000 années)		
Perte annuelle moyenne	**300 000 $**	**299 929,74 $**
Probabilité que la perte dépasse 300 000 $	—	**48,74 %**
Probabilité que la perte dépasse 400 000 $	—	**0,10 %**
Quantile à 95 % de la perte annuelle	—	**351 618,80 $**

Valeurs théoriques calculées à partir des hypothèses : $E[S]$ = 1 000 × 0,2 × 1 500 = 300 000 $. « — » : non calculée dans ce document.

Interprétation

Première année simulée. Les valeurs sont proches de la théorie sans l'égaler (205 sinistres au lieu de 200, 811 assurés sans sinistre au lieu d'environ 819, un coût moyen de 1 463,88 $ au lieu de 1 500 $). Ces écarts relèvent du hasard ; une seule année ne dit rien de la qualité du modèle.

Perte annuelle moyenne. La moyenne simulée (299 929,74 $) est à environ 70 $ de la valeur théorique, bien en deçà de l'erreur-type de 300 $. Cela soutient la cohérence de l'implémentation avec le modèle, mais pas le réalisme du modèle lui-même.

Probabilités de dépassement. La probabilité de dépasser 300 000 $ est de 48,74 %, légèrement sous 50 % : la distribution de S est asymétrique vers la droite, quelques années à pertes élevées tirent la moyenne vers le haut et la médiane se situe un peu sous la moyenne. Ces probabilités sont des **estimations** issues de simulations (erreur-type d'environ 0,5 point de pourcentage pour 48,74 %). L'estimation de 0,10 % est beaucoup plus incertaine : elle correspond à environ 10 dépassements sur 10 000, avec une erreur-type d'environ 0,03 point, soit de l'ordre de 30 % de sa valeur. Elle indique que dépasser 400 000 $ est rare dans ce modèle, sans en donner l'ordre de grandeur avec précision.

Quantile à 95 %. La valeur de 351 618,80 $ signifie que, dans 95 % des années simulées, la perte est inférieure ou égale à ce montant (et qu'elle le dépasse dans 5 % des années). Il se situe environ 51 700 $ au-dessus de la perte moyenne. Ce n'est ni une perte maximale, ni la perte moyenne des pires années, ni une exigence réglementaire de capital : c'est une description de la queue de la distribution *sous les hypothèses du modèle*.

Erreur de simulation et limites du modèle. L'erreur de simulation vient du nombre fini d'années simulées et diminue quand ce nombre augmente. Les limites du modèle viennent des hypothèses et subsistent même avec un très grand nombre de simulations.

3. Limites et pistes d'amélioration

Limites

Paramètres fictifs. Tous les résultats découlent de $\lambda = 0{,}2$ et de $\mu = 1\ 500$ \$, choisis à des fins pédagogiques : ils décrivent ce modèle, pas un risque réel.

Homogénéité des assurés. Tous les assurés ont la même fréquence. En pratique, le risque varie selon des caractéristiques individuelles (âge, usage, territoire, etc.) ; l'ignorer tend à sous-estimer la variabilité du nombre de sinistres.

Indépendance. Un événement touchant plusieurs assurés à la fois (une tempête, par exemple) ou un lien entre nombre et coût des sinistres rendrait l'hypothèse fausse. Une dépendance positive augmenterait la variance de S et épaissirait sa queue : les probabilités de dépassement et le quantile à 95 % seraient alors vraisemblablement sous-estimés.

Choix des distributions. Rien ne garantit que la loi de Poisson et la loi exponentielle décrivent bien des données réelles ; la queue légère de l'exponentielle est la principale source d'inquiétude pour les grosses pertes.

Absence de validation sur données réelles. La comparaison entre théorie et simulation vérifie la cohérence interne du code, pas la capacité du modèle à représenter la réalité. Il ne considère ni franchises, ni plafonds, ni réassurance, ni inflation, ni délais de règlement, et se limite à un an.

Pistes d'amélioration

1. Estimer les paramètres sur des données historiques : λ en rapportant le nombre de sinistres observés à l'exposition au risque (en années-assuré) et μ par le coût moyen observé, avec des intervalles de confiance.

2. Segmenter les assurés en groupes de risque ou modéliser la fréquence et le coût en fonction de variables explicatives.

3. Comparer des distributions (Poisson et binomiale négative ; exponentielle, gamma et lognormale) avec des graphiques quantile-quantile et des critères d'information.

4. Mener une analyse de sensibilité en faisant varier λ, μ et le nombre de simulations.

Conclusion

Ce projet m'a permis de mettre en œuvre une simulation Monte-Carlo, de la comparer aux valeurs théoriques et de distinguer l'erreur de simulation des limites du modèle. Il illustre le modèle fréquence-sévérité, la perte agrégée et la différence entre la perte moyenne et la queue de la distribution. Le modèle reste un outil d'apprentissage : ses paramètres sont fictifs, il n'a pas été validé sur des données réelles et il ne peut pas servir à tarifer un portefeuille réel.